PÓS-TECH DATA ANALYTICS · FIAP · TECH CHALLENGE FASE 2

Tech Challenge Fase 2
Qualidade dos vinhos



Classificação da qualidade de vinhos com Machine Learning · Apresentação executiva

Gabriel Alves da Silva · RM376192
Dimitria Doi · RM376922
Breno Plada Delege · RM377058
Yan Souza Montes · RM376051

A qualidade ainda depende da degustação



Hoje, enólogos avaliam aroma, sabor, acidez e equilíbrio de cada vinho.

É um trabalho valioso, mas que depende da experiência de cada avaliador.



Caro
Exige especialistas altamente qualificados



Demorado
Atrasa decisões de produção e de venda



Subjetivo
O resultado varia de avaliador para avaliador

A pergunta do projeto: as características físico-químicas do vinho conseguem indicar quais têm qualidade alta?

Como construímos a solução

METODOLOGIA

1

Análise exploratória

Investigamos a distribuição, as correlações e o desbalanceamento entre vinhos de qualidade alta e baixa/média.

2

Pré-processamento

Criamos duas classes: alta qualidade (nota ≥ 7) e baixa/média (nota < 7). Balanceamos a base de treino para o modelo aprender com ambas.

3

Modelagem

Treinamos três algoritmos de classificação e fizemos otimização dos modelos, para comparar desempenho.

4

Avaliação

Medimos acurácia, precisão, recall e F1-score para escolher o modelo mais confiável para o negócio.

Vinhos de alta qualidade são raros

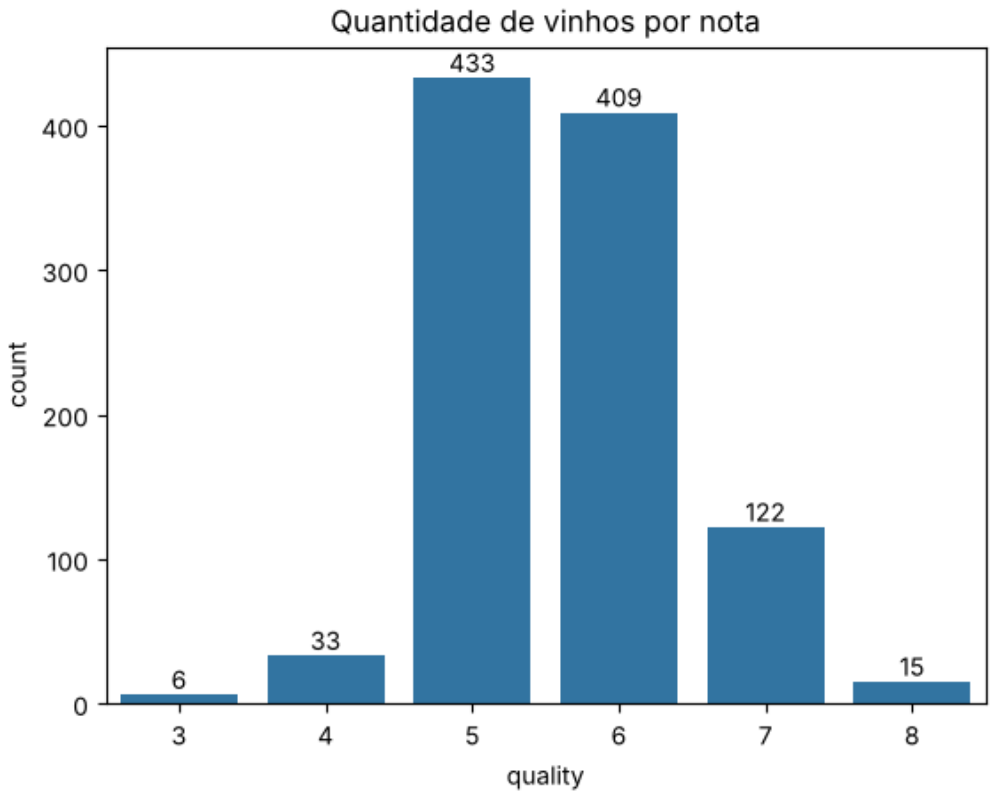
1.018

vinhos tintos analisados

13%

são de qualidade alta (nota 7 ou mais)

Base Wine Quality (Kaggle): 1.143 registros; 1.018 após remover 125 duplicados.

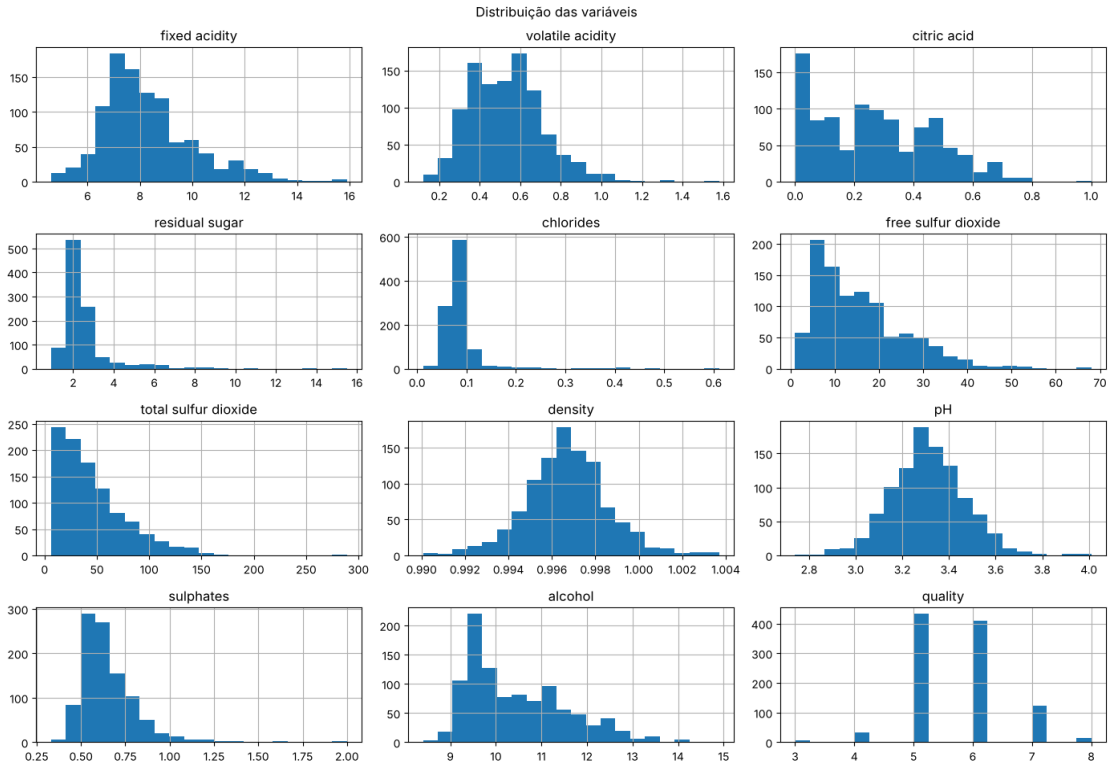


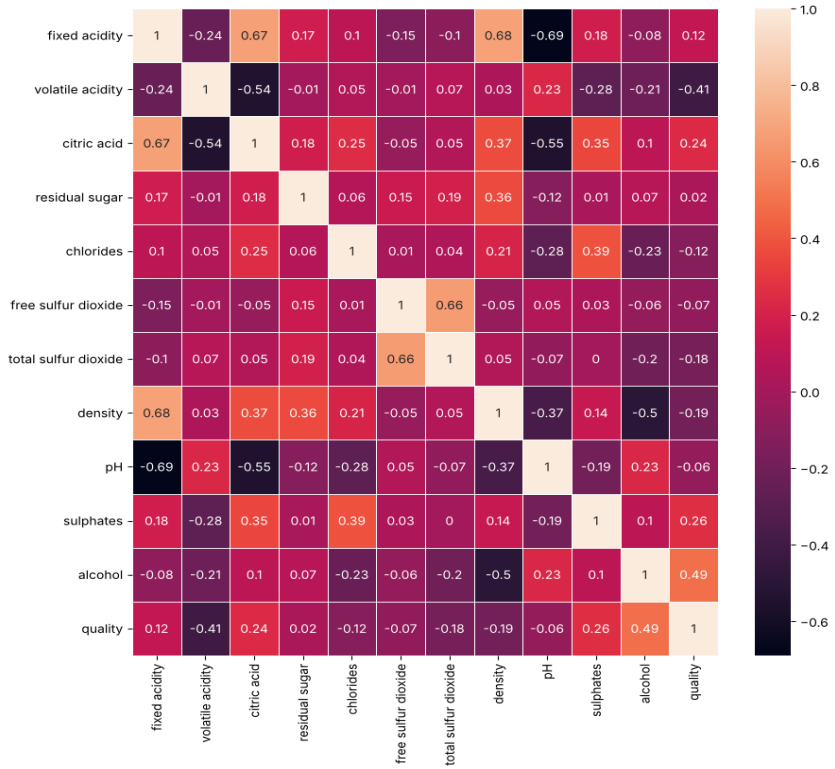
A maioria dos vinhos recebe nota 5 ou 6.

As notas 7 e 8, de qualidade alta, somam só 137 vinhos.

Esse desequilíbrio é o motivo de olharmos além da acurácia.

Distribuição e correlação das variáveis





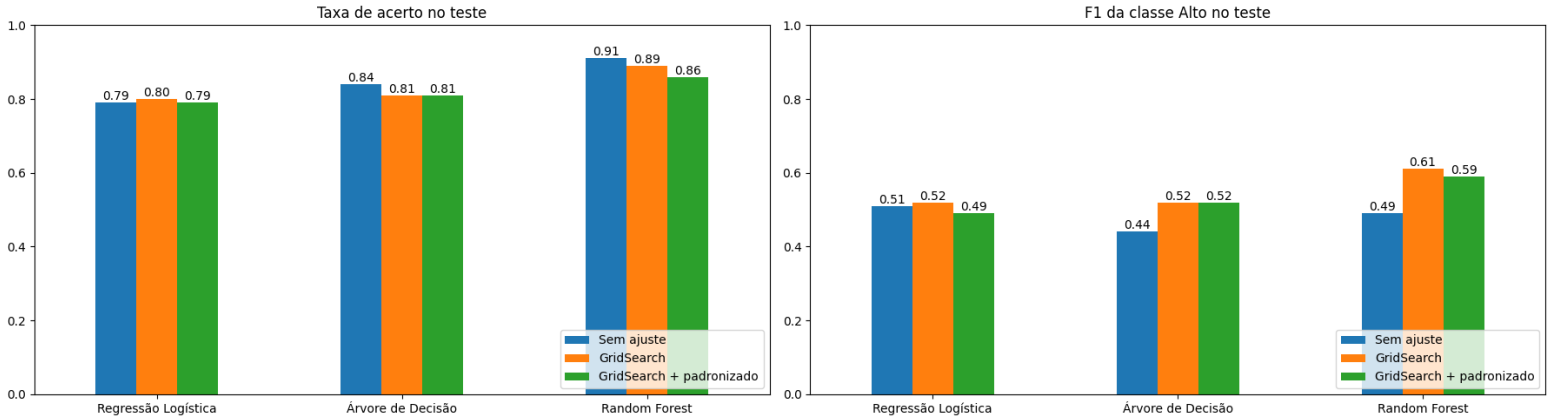
Distribuição

Densidade e pH seguem uma distribuição próxima da normal. Açúcar residual, cloretos e enxofre têm muitos valores baixos e poucos muito altos

Correlação com a nota

O álcool tem a maior relação positiva (+0,49) e a acidez volátil, a maior negativa (−0,41). Sulfatos (+0,26) e ácido cítrico (+0,24) vêm em seguida.

Random Forest é o modelo mais equilibrado

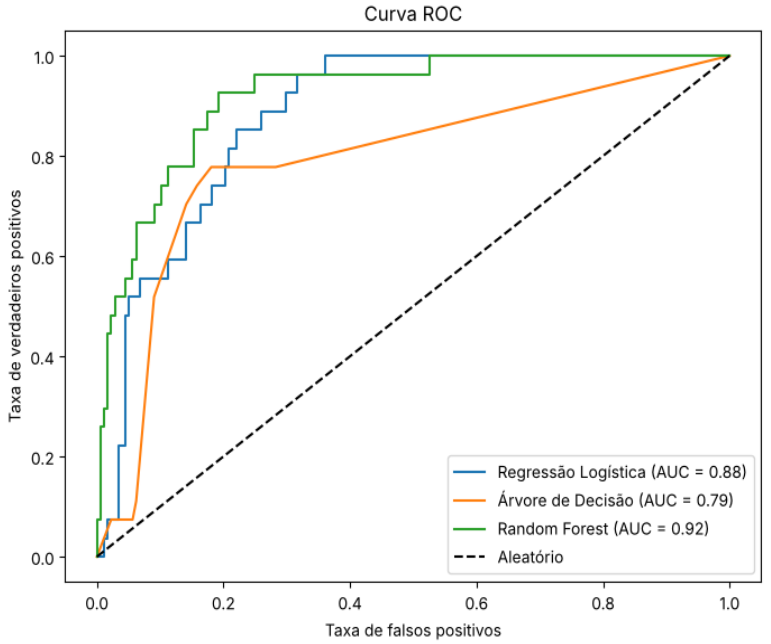


Barras verdes: versão final (GridSearch + padronizado).

Só a acurácia engana: um palpite “nenhum vinho tem qualidade alta” já acerta 87%.

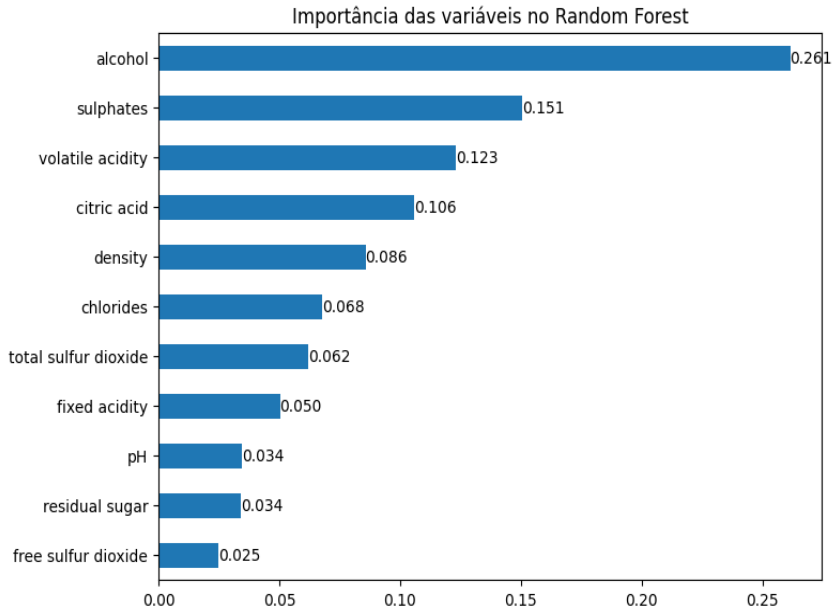
O erro tem custo: todo vinho apontado como alto passa pelo enólogo. A precisão evita revisões à toa, o recall evita perder vinhos bons e o F1 equilibra os dois.

Resultado: O modelo Random Forest foi escolhido como modelo final por apresentar o melhor desempenho geral nos dados de teste, alcançando 86% de acurácia, F1-score de 0,59 para a classe de interesse e AUC de 0,92. Esses resultados demonstram maior capacidade de generalização e discriminação entre as classes quando comparado à Regressão Logística e à Árvore de Decisão

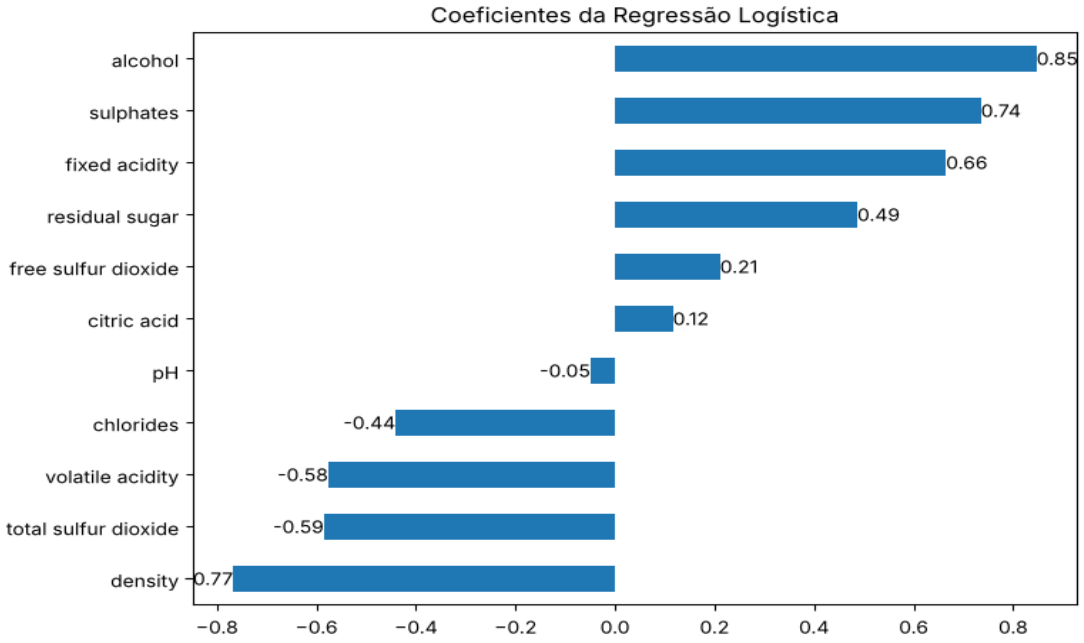


Modelo	Precisão	Recall	F1
Regressão Logística	0,36	0,78	0,49
Árvore de Decisão	0,40	0,78	0,53
Random Forest	**0,49**	**0,74**	**0,59**

O modelo confirma e aponta onde agir



Random Forest: álcool, acidez volátil e sulfatos são as medidas que mais pesam.



Regressão Logística: álcool e sulfatos aumentam a chance de qualidade alta; acidez volátil reduz.

Álcool: colher no ponto certo
Acompanhar a maturação da uva e a fermentação.

Acidez volátil: evitar o vinagre
Controlar higiene, oxigênio e temperatura.

Sulfatos: proteger sem exagerar
Manter nível adequado de conservantes.

Relações observadas nos dados; não garantem causa.

Analises Gerais

Triagem mais ágil: o modelo indica os lotes com maior chance de qualidade alta, direcionando a análise do enólogo para eles, com menos dependência da degustação de todos os lotes.

Com esse modelo, os produtores podem estimar a qualidade do vinho ainda durante o processo produtivo, permitindo ajustes antes de o produto chegar ao consumidor e aumentando a padronização da qualidade.

Cuidados

- O teste tem só 27 vinhos de qualidade alta: uma pequena mudança na base pode trocar o ranking dos modelos.
- Relação não é causa: aumentar o álcool artificialmente não melhora o vinho.
- O modelo aponta candidatos; a decisão final continua com o enólogo.

PÓS-TECH DATA ANALYTICS · FIAP · TECH CHALLENGE FASE 2

Obrigado!